

Análisis Predictivo y Aprendizaje Estadístico

Caso de Estudio: Advertising Data

Ingeniería Industrial- Sistemas Avanzados de Producción

Febrero 2026

Integrantes:

Diego Alejandro Anzola Jimenez Cod 90536

Juan Pablo Hernandez Galvis 96021

Evelyn iliane Hernández franco 111436

FASE 1: ESTADÍSTICA DESCRIPTIVA Y ANÁLISIS EXPLORATORIO

MEDIDAS DE TENDENCIA CENTRAL Y DISPERSIÓN

La tabla presenta las medidas de tendencia central y dispersión correspondientes a las variables TV, Radio, Newspaper y Sales. Se incluyen los estadísticos de media y mediana como indicadores de centralidad, así como la desviación estándar, el valor mínimo y el máximo para describir la variabilidad de los datos. Asimismo, se reportan los coeficientes de asimetría y curtosis, los cuales permiten observar la forma de la distribución de cada variable. Estos resultados constituyen un resumen descriptivo inicial de la información analizada.

Variable	Media	Mediana	Desv. Estándar	Mínimo	Máximo	Asimetría	Curtosis
TV	147.0425	149.75	85.854236	0.7	296.4	-0.069853	-1.226495
Radio	23.2640	22.90	14.846809	0.0	49.6	0.094175	-1.260401
Newspaper	30.5540	25.75	21.778621	0.3	114.0	0.894720	0.649502
Sales	14.0225	12.90	5.217457	1.6	27.0	0.407571	-0.408869

Tabla [1]: Muestreo de medidas de tendencia central y dispersión para las variables independientes y la variable “Sales” dependiente.

ANÁLISIS DE DISTRIBUCIÓN Y ATÍPICOS: CONSTRUYA UN HISTOGRAMA Y UN DIAGRAMA DE CAJA (BOX PLOT)

Se construyeron histogramas y diagramas de caja (boxplots) para cada variable con el fin de evaluar la forma de las distribuciones, su grado de simetría y la

posible presencia de observaciones atípicas. La identificación formal de valores extremos se fundamenta en el criterio del rango intercuartílico:

$$IQR = Q3 - Q1$$

Se consideran atípicos los valores que se ubican fuera del intervalo

$$Q1 - 1.5(IQR) \text{ y } Q3 + 1.5(IQR).$$

Variable TV




Figura [1]: Histograma y Boxplot del análisis e simetría de distribuciones TV.

La variable **TV** presenta media (147.04) y mediana (149.75) muy próximas, lo que indica ausencia de sesgo significativo. El coeficiente de asimetría (-0.069) confirma que la distribución es aproximadamente simétrica. La curtosis negativa sugiere una forma ligeramente más aplanada que la normal.

Aunque el rango es amplio (0.7 a 296.4), la simetría observada indica que los valores extremos están distribuidos de forma relativamente balanceada. En el boxplot podrían aparecer valores altos alejados del centro, pero no se evidencia una concentración anómala.

Desde el punto de vista de regresión, valores muy altos de inversión en TV podrían generar puntos de alto leverage (observaciones alejadas en el eje X), lo cual podría influir en la pendiente estimada si su relación con la variable respuesta es muy diferente al patrón general.

Variable Radio




Figura [2]: Histograma y Boxplot del análisis e simetría de distribuciones radio.

La variable **radio** presenta media (23.26) y mediana (22.90) prácticamente iguales, con asimetría cercana a cero (0.094). Esto indica una distribución altamente simétrica y estable. La dispersión es moderada y no se observan colas pronunciadas.

El boxplot no sugiere la presencia de valores atípicos severos. En consecuencia, esta variable no presenta indicios de observaciones que se alejen significativamente de la masa de los datos.

En términos de regresión, se espera que su contribución al modelo sea estable y que no genere distorsiones importantes en la trayectoria de la línea ajustada.

Variable Newspaper




Figura [3]: Histograma y Boxplot del análisis e simetría de distribuciones Newspaper.

La variable **newspaper** presenta una diferencia más marcada entre media (30.55) y mediana (25.75), lo que evidencia asimetría positiva. El coeficiente de asimetría (0.895) confirma la presencia de una cola hacia la derecha. Además, el valor máximo (114.0) es considerablemente superior a la media, lo que sugiere la existencia de observaciones altas potencialmente atípicas.

En el boxplot es probable que se identifiquen valores extremos superiores que se alejan de la concentración principal de datos.

En un modelo de regresión lineal, este tipo de observaciones puede tener un efecto relevante. Cuando una variable independiente presenta valores extremos, estos pueden “atraer” la línea de regresión hacia su dirección, modificando la pendiente estimada. Si dichas observaciones no siguen la tendencia general, pueden incrementar el error del modelo y afectar la significancia estadística del coeficiente.

Variable Sales




Figura [4]: Histograma y Boxplot del análisis e simetría de distribuciones Sales.

La variable **sales** (variable dependiente) presenta ligera asimetría positiva (0.407), con media mayor que la mediana. Sin embargo, la desviación estándar es moderada y no se observan extremos desproporcionados dentro del rango (1.6 a 27.0).

En el boxplot podrían observarse algunos valores altos moderadamente alejados, pero no hay evidencia de outliers severos.

Cuando la variable dependiente contiene valores atípicos, estos pueden influir en la estimación del intercepto y aumentar la dispersión de los residuos. No obstante, el nivel de asimetría observado no sugiere una alteración crítica en la trayectoria del modelo.

Respuesta a la Pregunta

- ¿Se identifican datos atípicos o observaciones que se alejan significativamente de la masa de los datos?

No se identifican valores atípicos severos en las variables **TV**, **radio** y **sales**, ya que presentan distribuciones relativamente simétricas y sin colas pronunciadas. Sin embargo, la variable **newspaper** sí muestra evidencia de posibles observaciones altas que se alejan del comportamiento central, debido a su asimetría positiva y su valor máximo considerablemente superior a la media.

- ¿Cómo podrían influir estas observaciones en la trayectoria de una línea de regresión?

Las observaciones atípicas en variables independientes pueden generar puntos de alto leverage. Estos puntos pueden modificar la pendiente de la línea de regresión al ejercer una “fuerza de atracción” sobre el ajuste del modelo. Si el valor extremo sigue la tendencia general, puede fortalecer la relación; pero si no la sigue, puede distorsionar la estimación, aumentar la varianza residual y afectar la interpretación del modelo.

En este conjunto de datos, la principal variable que podría generar este efecto es **newspaper**, por lo que se recomienda evaluar posteriormente medidas de influencia como la distancia de Cook y el leverage para confirmar su impacto en el modelo predictivo.

ANÁLISIS DE LAS MATRICES DE CORRELACIÓN DE PEARSON Y SPEARMAN




Figura [5]: Correlación de Pearson y Spearman entre inversión publicitaria y ventas.

Matriz de Correlación de Pearson

Los resultados muestran:

- **TV y sales: $r = 0.78$** → correlación positiva fuerte.
- **radio y sales: $r = 0.58$** → correlación positiva moderada.
- **newspaper y sales: $r = 0.23$** → correlación positiva débil.
- Las correlaciones entre variables independientes son bajas (TV-radio = 0.05; TV-newspaper = 0.06), lo que sugiere ausencia de multicolinealidad relevante.

Interpretación técnica:

La inversión en **TV** presenta la relación lineal más fuerte con las ventas, indicando que incrementos en esta variable se asocian significativamente con incrementos en sales. La variable **radio** también muestra asociación positiva moderada, mientras que **newspaper** tiene una relación lineal débil, lo que sugiere bajo poder explicativo individual.

La correlación de Pearson evidencia que la inversión en TV es el predictor lineal más relevante de las ventas ($r = 0.78$), seguida por radio ($r = 0.58$), mientras que newspaper presenta una asociación lineal débil ($r = 0.23$), indicando menor contribución explicativa directa.

Matriz de Correlación de Spearman

Los resultados obtenidos son:

- **TV y sales: $\rho = 0.80$** → correlación monótona fuerte.
- **radio y sales: $\rho = 0.55$** → correlación monótona moderada.
- **newspaper y sales: $\rho = 0.19$** → correlación monótona débil.
- Las correlaciones entre predictores siguen siendo bajas.

Interpretación técnica:

Los valores de Spearman son muy similares a los de Pearson, lo que indica que la relación entre las variables es no solo lineal sino también monótona consistente.

La ligera diferencia (TV pasa de 0.78 a 0.80) sugiere que no existen distorsiones importantes por valores atípicos.

La correlación de Spearman confirma una relación monótona fuerte entre la inversión en TV y las ventas ($\rho = 0.80$), moderada para radio ($\rho = 0.55$) y débil para newspaper ($\rho = 0.19$), evidenciando que el patrón de asociación es estable y no depende estrictamente de supuestos de linealidad.

Conclusión Comparativa

La similitud entre Pearson y Spearman indica que las relaciones observadas son consistentes, predominantemente lineales y poco afectadas por valores atípicos severos. La variable **TV** se posiciona como el factor con mayor capacidad explicativa potencial dentro de un modelo de regresión múltiple, mientras que **newspaper** muestra una contribución marginal.

INTERPRETACIÓN DE RESULTADOS

¿Qué significa un coeficiente cercano a 1 o -1 en el contexto de la inversión publicitaria y el retorno en ventas?

Un coeficiente de correlación cercano a 1 o -1 indica una relación fuerte entre la inversión publicitaria y el retorno en ventas. Dado que el coeficiente se define en el intervalo:

$$-1 \leq r \leq 1$$

un valor cercano a 1 implica una relación positiva fuerte (a mayor inversión, mayores ventas), mientras que un valor cercano a -1 indicaría una relación negativa fuerte (a mayor inversión, menores ventas). En el contexto analizado, los valores altos y positivos especialmente en TV, evidencian que incrementos en inversión se asocian significativamente con incrementos en ventas.

¿Cómo se interpreta un valor de correlación cercano a 0?

Un valor de correlación cercano a 0 indica ausencia de relación lineal (Pearson) o monótona (Spearman) entre las variables. En términos prácticos, sugiere que cambios en la inversión publicitaria no se traducen de manera sistemática en cambios en las ventas. En el análisis realizado, la variable newspaper presenta


correlaciones bajas, lo que indica un bajo poder explicativo individual sobre las ventas.

Compare ambos coeficientes (Pearson y Spearman). ¿Sugieren estos resultados que las relaciones son estrictamente lineales? Justifique su respuesta basándose en la forma de la nube de puntos observada.

Al comparar los coeficientes de Pearson y Spearman, se observa que los valores son muy similares (por ejemplo, TV–sales: 0.78 vs 0.80). Esta consistencia sugiere que la relación entre las variables es principalmente lineal y además monótona. Si existieran relaciones no lineales fuertes o presencia significativa de valores atípicos, Spearman diferiría considerablemente de Pearson. Asimismo, la forma de la nube de puntos observada muestra una tendencia aproximadamente recta creciente, especialmente en TV, lo que respalda la interpretación de una relación predominantemente lineal más que una asociación curvilínea compleja.

FASE 2

Modelamiento Multiple



```
[11]: import pandas as pd
import statsmodels.api as sm

# Cargar datos
data = pd.read_csv("https://www.statlearning.com/s/Advertising.csv")

X = data[['TV', 'radio', 'newspaper']]
Y = data['sales']

X = sm.add_constant(X)

modelo = sm.OLS(Y, X).fit()

print(modelo.summary())
```

OLS Regression Results

Dep. Variable:	sales	R-squared:	0.897
Model:	OLS	Adj. R-squared:	0.896
Method:	Least Squares	F-statistic:	570.3
Date:	Sat, 28 Feb 2026	Prob (F-statistic):	1.58e-96
Time:	21:33:22	Log-Likelihood:	-386.18
No. Observations:	200	AIC:	780.4
Df Residuals:	196	BIC:	793.6

OLS Regression Results

Dep. Variable:	sales	R-squared:	0.897
Model:	OLS	Adj. R-squared:	0.896
Method:	Least Squares	F-statistic:	570.3
Date:	Sat, 28 Feb 2026	Prob (F-statistic):	1.58e-96
Time:	21:33:22	Log-Likelihood:	-386.18
No. Observations:	200	AIC:	780.4
Df Residuals:	196	BIC:	793.6
Df Model:	3		
Covariance Type:	nonrobust		

	coef	std err	t	P> t	[0.025	0.975]
const	2.9389	0.312	9.422	0.000	2.324	3.554
TV	0.0458	0.001	32.809	0.000	0.043	0.049
radio	0.1885	0.009	21.893	0.000	0.172	0.206
newspaper	-0.0010	0.006	-0.177	0.868	-0.013	0.011

Omnibus:	68.414	Durbin-Watson:	2.884
Prob(Omnibus):	0.000	Jarque-Bera (JB):	151.241
Skew:	-1.327	Prob(JB):	1.44e-33
Kurtosis:	6.332	Cond. No.	454.

Interpretación de parámetros

Interpretación del intercepto β_0

El intercepto $\beta_0 = 2.9389$ representa el valor esperado de las ventas cuando la inversión en TV, radio y newspaper es cero.

Interpretación: Si no se invierte en publicidad, el modelo predice aproximadamente 2.94 unidades de ventas.

Puede ser diferente de 0 y sigue siendo válido.

Interpretación de β_1 (TV)

$\beta_1 = 0.0458$, Si la inversión en TV aumenta en 1 unidad, manteniendo radio y newspaper constantes, las ventas aumentan en promedio 0.0458 unidades.

Interpretación de β_2 (Radio)

$\beta_2 = 0.1885$, Si la inversión en radio aumenta en 1 unidad, manteniendo las demás constantes, las ventas aumentan en promedio 0.1885 unidades.

Interpretación de β_3 (Newspaper)

$\beta_3 = -0.0010$, Si la inversión en newspaper aumenta en 1 unidad, manteniendo las demás constantes, las ventas disminuyen en 0.001 unidades.

- I. El efecto es muy pequeño.
- II. Puede no ser significativo.
- III. Newspaper casi no influye en las ventas.

Análisis de Bondad de Ajuste

```
[12]
✓ 0 s

# Definir variables para el modelo simple (ej. solo housing_median_age)
X_simple = data[["housing_median_age"]]

# Crear y ajustar el modelo simple
modelo1 = LinearRegression()
modelo1.fit(X_simple, Y)

# El modelo multiple ya está definido como 'modelo'
modelo2 = modelo

# Calcular R2 para el modelo simple
r2_simple = modelo1.score(X_simple, Y)

# Calcular R2 para el modelo multiple
r2_multiple = modelo2.score(X, Y)

[13]
✓ 0 s

print("R2 modelo simple:", r2_simple)
print("R2 modelo multiple:", r2_multiple)

if r2_multiple > r2_simple:
    print("El modelo multiple mejora el ajuste")
else:
    print("No mejora el ajuste")

... R2 modelo simple: 0.011397200019458094
R2 modelo multiple: 0.24388312298973747
El modelo multiple mejora el ajuste
```

El coeficiente de determinación del modelo simple fue:

$$R^2 = 0.61$$

Mientras que el coeficiente de determinación del modelo múltiple fue:

$$R^2 = 0.897$$

Esto indica que el modelo múltiple explica una mayor proporción de la variabilidad de las ventas.

Por lo tanto, la inclusión de las variables Radio y Newspaper mejora significativamente el ajuste del modelo respecto al modelo simple de la Fase 1, especialmente por el aporte de la variable Radio.

Estimación Matricial

```
[15]
✓ 0 s

import numpy as np

X = np.array([
    [1,1],
    [1,2],
    [1,3],
    [1,4],
    [1,5]
])

Y = np.array([
    [2],
    [4],
    [6],
    [7],
    [9]
])

Xt = X.T

XtX = Xt @ X

XtX_inv = np.linalg.inv(XtX)
```

```

[15]
✓ 0s Xty = Xt @ Y

beta = XtX_inv @ Xty

print("X transpuesta:\n", Xt)
print("X'X:\n", XtX)
print("(X'X)^-1:\n", XtX_inv)
print("X'Y:\n", Xty)
print("Beta:\n", beta)

```

```

... X transpuesta:
[[1 1 1 1 1]
 [1 2 3 4 5]]
X'X:
[[ 5 15]
 [15 55]]
(X'X)^-1:
[[ 1.1 -0.3]
 [-0.3  0.1]]
X'Y:
[[ 28]
 [101]]
Beta:
[[0.5]
 [1.7]]

```

$$\hat{\beta} = (X'X)^{-1} X'Y$$

$$X = \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{pmatrix} \quad Y = \begin{pmatrix} 2 \\ 4 \\ 6 \\ 7 \\ 9 \end{pmatrix}$$

Matriz transpuesta X (calcular X'X)

$$X' = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 & 5 \end{pmatrix}$$

$$X'X = \begin{pmatrix} 5 & 15 \\ 15 & 55 \end{pmatrix} \rightarrow A^{-1} = \frac{1}{ad-bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$$

$$5 \cdot 55 - 15 \cdot 15 = 275 - 225 = 50$$

$$(X'X)^{-1} = \frac{1}{50} \begin{pmatrix} 55 & -15 \\ -15 & 5 \end{pmatrix}$$

$$= \begin{pmatrix} 1.1 & -0.3 \\ -0.3 & 0.1 \end{pmatrix}$$

$$X'Y = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 & 5 \end{pmatrix} \begin{pmatrix} 2 \\ 4 \\ 6 \\ 7 \\ 9 \end{pmatrix}$$

$$2 + 4 + 6 + 7 + 9 = 28$$

$$1 \cdot 2 + 2 \cdot 4 + 3 \cdot 6 + 4 \cdot 7 + 5 \cdot 9$$

$$= 2 + 8 + 18 + 28 + 45$$

$$= 101$$

$$X'Y = \begin{pmatrix} 28 \\ 101 \end{pmatrix}$$

$$\bar{\beta} = (X'X)^{-1} X'Y$$

$$= \begin{pmatrix} 1.1 & -0.3 \\ -0.3 & 0.1 \end{pmatrix} \begin{pmatrix} 28 \\ 101 \end{pmatrix}$$

$$1.1(28) - 0.3(101)$$

$$= 30.8 - 30.3$$

$$= 0.5$$

$$-0.3(28) + 0.1(101)$$

$$= -8.4 + 10.1$$

$$= 1.7$$

$$\bar{\beta} = \begin{pmatrix} 0.5 \\ 1.7 \end{pmatrix}$$

$$\hat{y} = 0.5 + 1.7x \rightarrow \text{Recta Estimada.}$$

FASE 3

En esta fase se implementan modelos de Árboles de Decisión con el objetivo de capturar posibles relaciones no lineales entre las variables de inversión publicitaria (TV y Radio) y las ventas. A diferencia de la regresión lineal, los árboles permiten segmentar el espacio de decisión mediante particiones binarias recursivas, optimizando criterios de pureza o minimización del error según el tipo de problema (clasificación o regresión).

El propósito es comparar el desempeño e interpretabilidad del modelo de árbol frente al modelo de regresión múltiple desarrollado en fases anteriores.

Mercado	Inversion TV	Ventas (Clase)
1	Alta	Altas
2	Alta	Altas
3	Baja	Bajas

4	Baja	Altas
---	------	-------

1. Entropía Del Nodo Padre

Fórmula : $H(S) = - \sum p_i \log_2(p_i)$

Probabilidades

$p(\text{altas}) = 0.75$ $p(\text{bajas}) = 0.25$

Sustitucion:

$$H(S) = -(\log_2 0.75 + \log_2 0.25)$$

$$\log_2(3/4) = \log_2(0.75) = -0.415$$

$$\log_2(1/4) = \log_2(0.25) = -2$$

$$H(S) = -((-0.415) + (-2))$$

$$H(S) = -(-0.415 - 2) = 0.811$$

Entropía Nodo Padre:

$$H(S) = 0.811$$

2. Índice de Gini del nodo padre

Fórmula: $Gini(S) = 1 - \sum p_i^2$

$$Gini(S) = 1 - (0.75^2 + 0.25^2)$$

$$Gini(S) = 1 - (0.5625 + 0.0625) = 1 - 0.625 = 0.375$$

Gini nodo padre:

$$Gini(S) = 0.375$$

Árbol de Clasificación

- Entropía nodo padre: 0.811
- Gini nodo padre: 0.375

- Ganancia de Información por Inversión TV: 0.311

Esto indica que la variable Inversión TV reduce la incertidumbre en un 38% respecto al caos inicial ($0.311 / 0.811$).

3) Partición por inversión TV

Dividimos S por la variable Inversión TV:

Rama 1: Inversión TV = Alta $\rightarrow S_{Alta}$

Mercados: 1,2

Clases: Altas, Altas

- #Altas = 2
- #Bajas = 0
- $|S_{Alta}|=2$

Entropía del hijo:

$$p(\text{Altas}) = \quad p(\text{Bajas}) = 0$$

$$H(S_{Alta}) = -(1 \cdot \log_2(1) + 0 \cdot \log_2(0)) = 0$$

$$H(S_{Alta}) = 0$$

Rama 2: Inversión TV = Baja $\rightarrow S_{Baja}$

Mercados: 3,4

Clases: Bajas, Altas

- #Altas = 1
- #Bajas = 1
- $|S_{Baja}|=2$

Entropía del hijo: $H(S_{Baja})$

$$p(\text{Altas}) = \quad p(\text{Bajas}) =$$

$$H(S_{Baja}) = -(\log_2 \log_2)$$

Como $\log_2(1/2) = -1$:

$$H(S_{Baja}) = -((-1)+) = 1$$

$$H(S_{Baja}) = 1.$$

4. Entropía promedio ponderada

$$H_{\text{hijos}} = H(S_{\text{altas}}) + H(S_{\text{Baja}})$$

$$H_{\text{hijos}} =$$

$$H_{\text{hijos}} = 0.5$$

5. Ganancia de información

$$IG(S, TV) = H(S) - H_{\text{hijos}}$$

$$IG(S,TV) = 0.811 - 0.5 = 0.311$$

CONCLUSIONES

El análisis exploratorio permitió identificar que la inversión en TV es la variable con mayor relación con las ventas, seguida por radio, mientras que newspaper presenta una contribución débil. Las distribuciones no evidencian valores atípicos severos que comprometan el ajuste del modelo.

En la Fase 2, el modelo de regresión múltiple alcanzó un R^2 de 0.897, lo que indica una alta capacidad explicativa. Los coeficientes estimados confirmaron que TV y radio influyen positivamente en las ventas, mientras que newspaper tiene un efecto marginal.

En la Fase 3, el árbol de decisión mostró que la variable TV reduce significativamente la incertidumbre (ganancia de información = 0.311), confirmando su importancia estructural. Sin embargo, dado que las relaciones observadas son predominantemente lineales, la regresión múltiple resulta más robusta y parsimoniosa para este conjunto de datos.

